



支持向量机

主讲人：屠恩美

《机器学习与知识发现》



上海交通大学

SHANGHAI JIAO TONG UNIVERSITY


凸集






- 对任意的 $\sum_{i=1}^n \alpha_i = 1, \alpha_i \geq 0$, 如果集合 X 具有如下性质

$$\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n \in X \Rightarrow \left(\sum_{i=1}^n \alpha_i \mathbf{x}_i \right) \in X$$

Convex set




Non-convex set



凸函数




- 定义: $tf(x_1) + (1-t)f(x_2) \geq f(tx_1 + (1-t)x_2)$, $0 \leq t \leq 1$
- 判断: 如果 $f(x)$ 二阶可导, $f''(x) \geq 0$
- 常见凸函数: $\mathbf{a}^T \mathbf{x} + b$, $\|\mathbf{x}\|_p$, $e^{\mathbf{a}^T \mathbf{x} + b}$, $\text{tr}(\mathbf{A}^T \mathbf{X})$




凸优化




- 凸函数在凸集上的最小值优化问题就是凸优化
- 凸优化具有全局唯一最小值（不同初始条件都能获得最优解）



凸函数 - 凸集



凸函数 - 非凸集



非凸函数 - 凸集

优化回顾



- 有约束优化问题

$$\min_{\mathbf{x} \in \mathbb{R}^d} f_0(\mathbf{x})$$

目标函数

$$\text{s. t. } f_i(\mathbf{x}) \leq 0, \quad i = 1, 2, \dots, p$$

不等式约束

$$g_j(\mathbf{x}) = 0, \quad j = 1, 2, \dots, q$$

等式约束

- 如果 $f_i(\mathbf{x})$ 是凸函数, 且 $g_i(\mathbf{x})$ 是线性函数, 则该优化问题为凸优化
- 拉格朗日乘子函数

$$\begin{aligned} L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\tau}) &= f_0(\mathbf{x}) + \sum_{i=1}^p \lambda_i f_i(\mathbf{x}) + \sum_{j=1}^q \tau_j g_j(\mathbf{x}) \\ &= f_0(\mathbf{x}) + \boldsymbol{\lambda}^T \mathbf{F}(\mathbf{x}) + \boldsymbol{\tau}^T \mathbf{G}(\mathbf{x}) \end{aligned}$$

凸优化与KKT条件



- 拉格朗日对偶函数

$$g(\lambda, \tau) = \inf_{\mathbf{x} \in D} L(\mathbf{x}, \lambda, \tau) = \left(f_0(\mathbf{x}) + \lambda^T \mathbf{F}(\mathbf{x}) + \tau^T \mathbf{G}(\mathbf{x}) \right) \Big|_{\mathbf{x}^* \leftarrow \nabla L_{\mathbf{x}}(\mathbf{x}^*, \lambda, \tau) = 0}$$

- 对偶问题

$$\begin{aligned} \max \quad & g(\lambda, \tau) \\ \text{s.t.} \quad & \lambda_i \geq 0, \quad i = 1, \dots, p \end{aligned}$$


- KKT条件：最优解的必要条件(凸优化时也是充分必要条件)

- 原始问题约束 $f_i(\mathbf{x}) \leq 0, \quad i = 1, 2, \dots, p; \quad g_j(\mathbf{x}) = 0, \quad j = 1, 2, \dots, q$
- 对偶问题约束 $\lambda_i \geq 0, \quad i = 1, \dots, p$
- 互补松弛 $\lambda_i f_i(\mathbf{x}) = 0, \quad i = 1, \dots, p$
- 梯度消失 $\nabla L_{\mathbf{x}}(\mathbf{x}, \lambda, \tau) = 0$

点到直线的距离

- \mathbf{x}_0 到直线 $\mathbf{w}^T \mathbf{x} + b = 0$ 的距离


$$\begin{aligned}
 d &= \|\mathbf{x}_0 - \mathbf{x}_1\| \cos \theta \\
 &= \frac{\|\mathbf{x}_0 - \mathbf{x}_1\| \|\mathbf{w}\| \cos \theta}{\|\mathbf{w}\|} \\
 &= \frac{|\mathbf{w}^T (\mathbf{x}_0 - \mathbf{x}_1)|}{\|\mathbf{w}\|} \quad (\text{dot product definition}) \\
 &= \frac{|\mathbf{w}^T \mathbf{x}_0 - \mathbf{w}^T \mathbf{x}_1|}{\|\mathbf{w}\|} \\
 &= \frac{|\mathbf{w}^T \mathbf{x}_0 + b|}{\|\mathbf{w}\|} \quad (\text{line equation } \mathbf{w}^T \mathbf{x}_1 + b = 0)
 \end{aligned}$$



两类线性可分问题




- 考虑两类线性可分情况：在样本空间中寻找一个超平面, 将不同类别的样本分开



两类线性可分问题




- Q: 将训练样本分开的超平面可能有很多, 哪一个好呢?



- A: 应选择“**正中间**”, 容错性好, 稳健性高, 泛化能力最强.

两类线性可分问题


- 通过适当的比例缩放 $\mathbf{w} \rightarrow \tau \mathbf{w}, b \rightarrow \tau b$ 使正类 ≥ 1 , 负类 ≤ -1 , 而距离超平面最近的几个样本使等式成立



考虑正类缩放(负类同理) $\mathbf{w}^T \mathbf{x} + b > M \rightarrow \frac{1}{M} \mathbf{w}^T \mathbf{x} + \frac{1}{M} b > 1 \rightarrow \tau = \frac{1}{M}$

间隔与支持向量

- 两条蓝线间隔 $\gamma = \frac{2}{\|\mathbf{w}\|}$?



支持向量机



- 假设有 n 个样本 $D = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$, $y_i \in \{+1, -1\}$
- 最大间隔: 寻找参数 \mathbf{w} 和 b , 使得 γ 最大, 同时满足**正确分类**的约束条件.

$$\arg \max_{\mathbf{w}, b} \frac{2}{\|\mathbf{w}\|}$$

$$\text{s.t. } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, i = 1, 2, \dots, n$$



$$\arg \min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2$$

$$\text{s.t. } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, i = 1, 2, \dots, n$$

凸优化, 存在全局唯一最小值!

问题求解



- 第一步：引入拉格朗日乘子 $\alpha_i \geq 0$ 得到拉格朗日函数

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1)$$

- 第二步：令 $L(\mathbf{w}, b, \boldsymbol{\alpha})$ 对 \mathbf{w} 和 b 的偏导为零可得

$$\mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i, \quad \sum_{i=1}^n \alpha_i y_i = 0$$

- 第三步：回代得到一个新的优化问题

$$\min_{\boldsymbol{\alpha}} \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j - \sum_{i=1}^n \alpha_i$$

$$\text{s.t.} \quad \sum_{i=1}^n \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i = 1, 2, \dots, n$$

对偶问题

求解方法-SMO



- 基本思路：不断执行如下两个步骤直至收敛。
 - 第一步：选取一对需更新的变量 α_i 和 α_j 。
 - 第二步：固定 α_i 和 α_j 以外的参数, 求解对偶问题更新 α_i 和 α_j
- 上面第二步：仅考虑 α_i 和 α_j 时, 对偶问题的约束变为

$$\alpha_i y_i + \alpha_j y_j = - \sum_{k \neq i, j} \alpha_k y_k, \quad \alpha_i \geq 0, \quad \alpha_j \geq 0$$

用一个变量表示另一个变量, 再代入对偶问题中可得一个**单变量**的二次规划, 该问题具有**闭式解**. (舍弃不符合约束条件的负数解)

- 偏移项 b : 通过支持向量方程来确定 $y_i f(\mathbf{x}_i) = 1$
- 最终判决 $y = \text{sign}[f(\mathbf{x}_i)]$, $\text{sign}[x]$ 表示取 x 符号

解得稀疏性




- 由KKT条件知，最优解存在的必要条件：

$$\begin{cases} y_i f(\mathbf{x}_i) - 1 \geq 0 \\ \alpha_i \geq 0 \\ \alpha_i (y_i f(\mathbf{x}_i) - 1) = 0 \end{cases}, \quad i = 1, \dots, n$$

- 因为大多数点都是类内点，即 $y_i f(\mathbf{x}_i) > 1$ ，因此多数的 $\alpha_i = 0$

支持向量机解的**稀疏性**：训练完成后，大部分的训练样本都不需保留，最终模型仅与**支持向量**有关。

支持向量



小结一下



原始问题

$$\begin{aligned} \arg \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1, i = 1, 2, \dots, n \end{aligned}$$



对偶问题

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j - \sum_{i=1}^n \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^n \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i = 1, 2, \dots, n \end{aligned}$$



$$\boldsymbol{\alpha}^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_n^*)$$




预测函数

$$y = \text{sign}(f(\mathbf{x}_i)) = \text{sign}(\mathbf{w}^T \mathbf{x} + b), \quad \mathbf{w} = \sum_{i=1}^n \alpha_i^* y_i \mathbf{x}_i$$

线性不可分情况



- 现实问题中多数情况是线性不可分的



颜色标记的为不满足分类约束的样本

线性不可分情况


- 引入松弛变量

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i$$

$$s.t. \quad y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i$$

$$\xi_i \geq 0, \quad i = 1, 2, \dots, m$$

ξ_i 表示第 i 个样本不满足
分类约束条件的程度(松弛性)



线性不可分情况



- 构建拉格朗日乘子

$$L(\mathbf{w}, b, \xi, \boldsymbol{\alpha}, \boldsymbol{\beta}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1) - \sum_{i=1}^n \beta_i \xi_i$$

- 对偶问题

全内积形式出现

$$\min_{\boldsymbol{\alpha}} \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \boxed{\mathbf{x}_i^T \mathbf{x}_j} - \sum_{i=1}^n \alpha_i$$


$$\text{s.t.} \quad \sum_{i=1}^n \alpha_i y_i = 0, \quad 0 \leq \alpha_i \boxed{\leq C}, \quad i = 1, 2, \dots, n$$

- 求解与线性可分类似，通过对偶问题求解（SMO中舍弃不满足约束的解）

特征映射



- 将样本从原始**输入空间**映射到一个更高维的**特征空间**, 使得输入空间中**线性不可分**样本在这个特征空间内变得**线性可分**



特征映射后的SVM



- 设样本 \mathbf{x} 映射后的向量为 $\phi(\mathbf{x})$ ，划分超平面为 $f(\mathbf{x}) = \mathbf{w}^T \phi(\mathbf{x}) + b$

原始问题

$$\begin{cases} \arg \max_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t. } y_i (\mathbf{w}^T \phi(\mathbf{x}_i) + b) \geq 1, \quad i = 1, 2, \dots, n \end{cases}$$

对偶问题

$$\begin{cases} \min_{\alpha} \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j) - \sum_{i=1}^n \alpha_i \\ \text{s.t. } \sum_{i=1}^n \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i = 1, 2, \dots, n \end{cases}$$

预测

$$f(\mathbf{x}) = \mathbf{w}^T \phi(\mathbf{x}) + b = \sum_{j=1}^n \alpha_j y_j \phi(\mathbf{x}_j)^T \phi(\mathbf{x}) + b$$

只以内积的形式出现，不需计算出映射，只要设计核函数 $k(\mathbf{x}, \mathbf{y}) = \phi(\mathbf{x})^T \phi(\mathbf{y})$

核函数与核矩阵



- 核函数: $k: \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$
 - 对称 $k(\mathbf{x}, \mathbf{y}) = k(\mathbf{y}, \mathbf{x})$
 - 半正定特性 $\sum_{i=1}^n c_i c_j k(\mathbf{x}_i, \mathbf{x}_j) \geq 0$, 对任意点序列 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 和数列 c_1, c_2, \dots, c_n
- 任一核函数 k 都可以找到一个映射函数 $\phi(\mathbf{x})$, 从而可以把 k 写成唯一的内积形式 $k(\mathbf{x}, \mathbf{y}) = \langle \phi(\mathbf{x}), \phi(\mathbf{y}) \rangle = \phi(\mathbf{x})^T \phi(\mathbf{y})$
- 常见核函数

名称	表达式	参数
线性核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^T \mathbf{x}_j$	
多项式核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^T \mathbf{x}_j)^d$	$d \geq 1$ 为多项式的次数
高斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ ^2}{2\delta^2}\right)$	$\delta > 0$ 为高斯核的带宽(width)
拉普拉斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ }{\delta}\right)$	$\delta > 0$
Sigmoid核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^T \mathbf{x}_j + \theta)$	\tanh 为双曲正切函数, $\beta > 0, \theta < 0$

核函数与核矩阵



- 核矩阵：核函数 k 在点列 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 上的采样矩阵称为其对应的核矩阵

$$\mathbf{K} = \begin{bmatrix} k(\mathbf{x}_1, \mathbf{x}_1) & k(\mathbf{x}_1, \mathbf{x}_2) & \cdots & k(\mathbf{x}_1, \mathbf{x}_n) \\ k(\mathbf{x}_2, \mathbf{x}_1) & k(\mathbf{x}_2, \mathbf{x}_2) & \cdots & k(\mathbf{x}_2, \mathbf{x}_n) \\ \vdots & \vdots & \ddots & \vdots \\ k(\mathbf{x}_n, \mathbf{x}_1) & k(\mathbf{x}_n, \mathbf{x}_2) & \cdots & k(\mathbf{x}_n, \mathbf{x}_n) \end{bmatrix} = \begin{bmatrix} \mathbf{K}_{11} & \mathbf{K}_{12} & \cdots & \mathbf{K}_{1n} \\ \mathbf{K}_{21} & \mathbf{K}_{22} & \cdots & \mathbf{K}_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{K}_{n1} & \mathbf{K}_{n2} & \cdots & \mathbf{K}_{nn} \end{bmatrix}$$

- 半正定矩阵：对称且所有特征值大于等于0
- 高斯核函数为例

$$\mathbf{K}_{ij} = k(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2}\right)$$

基于核的SVM



原始问题

$$\begin{cases} \arg \max_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad y_i (\mathbf{w}^T \phi(\mathbf{x}_i) + b) \geq 1, \quad i = 1, 2, \dots, n \end{cases}$$

对偶问题

$$\begin{cases} \min_{\alpha} \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{K}_{ij} - \sum_{i=1}^n \alpha_i \\ \text{s.t.} \quad \sum_{i=1}^n \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i = 1, 2, \dots, n \end{cases}$$

预测

$$f(\mathbf{x}) = \mathbf{w}^T \phi(\mathbf{x}) + b = \sum_{j=1}^n \alpha_j y_j k(\mathbf{x}_j, \mathbf{x}) + b$$

总结



线性可分

$$\left\{ \begin{array}{l} \arg \min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1, i = 1, 2, \dots, n \end{array} \right.$$

线性不可分

$$\left\{ \begin{array}{l} \min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \\ \text{s.t.} \quad y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad i = 1, 2, \dots, n \end{array} \right.$$

特征映射

$$\left\{ \begin{array}{l} \arg \max_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad y_i (\mathbf{w}^T \phi(\mathbf{x}_i) + b) \geq 1, \quad i = 1, 2, \dots, n \end{array} \right.$$

支持向量机软件包



- LIBSVM

<http://www.csie.ntu.edu.tw/~cjlin/libsvm/>

- LIBLINEAR

<http://www.csie.ntu.edu.tw/~cjlin/liblinear/>

- SVMlight 、 SVMperf 、 SVMstruct

http://svmlight.joachims.org/svm_struct.html

- Pegasos

<http://www.cs.huji.ac.il/~shais/code/index.html>